Modelli AMD Token Factory: specifiche e compatibilità con NVIDIA H100

H100 SXM/PCIe = 80 GB HBM3, FP8 nativo, nessun FP4 nativo. Dati aggiornati a ottobre 2026.

Modello	Architettura	Parametri (totali / attivi)	Contesto	Input	Licenza	1× H100 80 GB?	Configurazione minima realistica
MinerU2.5-Pro	VLM per parsing documenti (stile Qwen2-VL)	1,2B, denso	8K	immagini di pagine -> Markdown, HTML, LaTeX	Apache 2.0	**Sì**, ~3 GB	1 GPU, ne usa una minima parte
MiniCPM5-2B	Denso, architettura Llama, modalità think/no-think	2,5B	128K	solo testo	Apache 2.0	**Sì**, ~5 GB	1 GPU
Qwen3.8-27B	Denso, multimodale	27B (28B con l'encoder visivo)	256K	testo e immagini	Apache 2.0	**Sì**: ~56 GB BF16, ~28 GB FP8	1 GPU. Con contesti lunghi conviene FP8 per lasciare memoria alla KV cache
Gemma-4-31B-IT	Denso, attenzione ibrida (finestra scorrevole + globale)	30,7B	256K	testo, immagini, video	Apache 2.0	**Sì**: ~62 GB BF16, ~31 GB FP8	1 GPU. In BF16 resta poco spazio per la KV cache, meglio FP8
Qwen3.8-Flash-Next	MoE, anteprima dell'architettura Qwen4	125B / ~6B (+ tabella N-gram da 51B in RAM di sistema)	256K (fino a 1M)	testo	Qwen Community	**No** (solo INT4, molto stretto)	2× H100 in FP8, 4× in BF16
DeepSeek-V4-Flash	MoE	284B / 13B	1M	testo	MIT	**No**	4× H100 (stretto) o 8× (comodo). Checkpoint FP4+FP8 da ~160 GB
DeepSeek-V4-Flash-Vision-Exp	Come V4-Flash + vision transformer da ~0,5B	284B / 13B	1M	testo e immagini	MIT	**No**	4–8× H100. Checkpoint da ~168 GB
MiMo-V2.6-Flash (Xiaomi)	MoE, attenzione ibrida	309B / 15B	1M	testo, immagini, video, audio	MIT	**No**	8× H100 in FP8 (~310 GB)
GLM-5.3-Flash (Zhipu)	MoE, attenzione sparsa + lineare	320B / 18B	1M	testo, immagini, video, documenti	MIT	**No**	8× H100 in FP8 (~320 GB)
DeepSeek-V4.1-Flash	MoE, attiva 8B in lettura e 16B in generazione	552B (una fonte: 748B con i parametri "Engram")	1M	testo e immagini	MIT	**No**	8× H100 come minimo. In FP8 completo probabilmente più di un nodo

FP4 su H100: i DeepSeek V4 distribuiscono i pesi degli expert in FP4, ma l'H100 (Hopper) non calcola nativamente in FP4 (lo fanno Blackwell, B200 e B300). vLLM/SGLang devono convertire i pesi al volo, oppure vanno portati in FP8, quasi raddoppiando la memoria (~290 GB per V4-Flash). Verificare il supporto della versione di vLLM installata sul cluster prima di prenotare GPU.

KV cache: i contesti da 1M token sono teorici su un nodo H100; nella pratica 32–128K token per richiesta.

Fonti e stime: gran parte dei dati proviene da aggregatori e annunci dei produttori, non dalle schede ufficiali su Hugging Face; alcune fonti divergono (es. totale di V4.1-Flash). I fabbisogni di memoria e le configurazioni GPU sono stime.